

情報理工学演習Ⅳ後半



北海道大学

情報理工学演習Ⅳ 知能ソフトウェア研究室分 第二回

担当: 坂地 泰紀

第二回の目標

1

1. コンペティションの流れを理解する
2. データをダウンロードする
3. タスクを理解する
4. データを理解する
5. 一度提出を行う



第二回の目標

2

1. コンペティションの流れを理解する
2. データをダウンロードする
3. タスクを理解する
4. データを理解する
5. 一度提出を行う



コンペティションで与えられるもの

教師あり学習のコンペでは主に以下の二つが与えられる

1. 訓練データ

- 目標値(正解)が与えられているデータ
- 参加者はこのデータを用いて予測モデルを作る(学習させる)

2. テストデータ

- 参加者には目標値(正解)が与えられていないデータ
- 運営側は正解が分かっている
- 参加者は「テストデータに対する予測」を提出
- 提出された予測結果に対して, 良さ(悪さ)を表すスコアが計算され, ランキング付けされる



コンペティションの流れ

1. データをダウンロードする
2. タスクを理解する
3. データを理解する
4. While 期日まで do:
 - A) 訓練データを用いて, 特徴設計, モデルの選択... などを行い, 予測モデルを構築
 - B) A)で学習した予測モデルを用いてテストデータの正解を予測
 - C) B)で予測した結果を提出 (1日3回まで)
 - D) 提出結果のスコアが計算・ランキングが更新されるので, 一喜一憂しつつ次回以降の投稿に活かす



第二回の目標

5

1. コンペティションの流れを理解する
2. データをダウンロードする
3. タスクを理解する
4. データを理解する
5. 一度提出を行う



データをダウンロードする

ダウンロードしたdataフォルダの中に以下のファイルがあればよい

- train.csv
- test.csv
- y_pred_example.csv

配布するサンプルプログラムを使う場合, dataフォルダを2026フォルダの中に入れて置くこと

Google Colabを用いる場合は, dataフォルダをGoogle Driveにアップロードしておくこと



第二回の目標

7

1. コンペティションの流れを理解する
2. データをダウンロードする
3. タスクを理解する
4. データを理解する
5. 一度提出を行う



タスクを理解する

楽曲の情報が与えられるのでその人気度を予測する

- 楽曲Aは人気度80
- 楽曲Bは人気度53...

評価指標: 平均二乗誤差(Mean Squared Error, MSE)

$$\frac{1}{N} \sum_{n=1}^N (y(x_n) - t_n)^2, \quad x_1, \dots, x_n : \text{テストデータ}$$

- $(y(x_n) - t_n)^2$: n 番目のデータ予測の悪さを表す. 正解と予測の差の絶対値が大きい(=外れている)と値が大きくなる
- 絶対値とは違い**連続的微分可能**→この評価指標を目的関数とする(=学習アルゴリズムで使う)ことが容易



第二回の目標

1. コンペティションの流れを理解する
2. データをダウンロードする
3. タスクを理解する
4. データを理解する
5. 一度提出を行う



データについて

楽曲について以下のメタ情報と音響特徴量が与えられる:

- アーティスト名 文字列
 - アルバム名 文字列
 - 楽曲名 文字列
 - 曲の長さ 数値
 - 曲の激しさ 数値
 - テンポ 数値
 - 人気度(訓練データのみ, テストデータのこの値を予測する)
数値
- など

訓練データ数: 79,267 テストデータ数: 34,152

文字列と数字の混在した合計19種類の入力情報から, 楽曲の人気度を予測する



データについて

train.csv: 訓練データ集合, 79,268行21列のCSVファイル

- 1行目: 各列(情報)の名前
- 2-79,268行目: 各行が1つのデータに対応
- 2-20列目: アーティスト名、アルバム名などの入力情報
- 21列目: 人気度(目標値, 正解)

test.csv: テストデータ集合, 34,153行20列のCSVファイル

- 1行目: 各列(情報)の名前
- 2-34,153行目: 各行が1つのデータに対応
- 2-20列目: 入力情報
- 21列目は存在しない, 21列目を予測する

y_pred_example.csv: 提出の例

- test.csvの予測された21列目を提出する
- i 行目の値をtest.csvの $i + 1$ 行目のデータの予測に対応させる
- 最後に空白の行があっても良い



1. コンペティションの流れを理解する
2. データをダウンロードする
3. タスクを理解する
4. データを理解する
5. 一度提出を行う



第二回の目標

y_pred_example.csvを提出してみましょう

- 今日中に自分で予測した結果を3回提出したいという強い意思を持つ方はやらなくても結構です

こちらからのコンペに関する説明は以上

- 毎回サンプルプログラムの配布とその説明を行いますが、必ずしも用いる必要はない
- ただし、毎週少なくとも一回は提出してください

1位を目指して頑張ってください

- ただし成績はレポートで評価されます



おわりに

質問ご意見, いつでもお気軽にどうぞ

- 授業に関係あれば「コンペに関する質問」でも「プログラミングに関する質問」でも「機械学習に関する質問」でも何でもどうぞ(基本的にはTA/TFに)
- 学生同士のディスカッション也大いに推奨します

アドバイス: 毎週コツコツやりましょう

- 一日に投稿できる最大数が決まっているので「締め切り前日に死ぬ気で頑張る」作戦はそもそも使えない可能性が高い
- コンペ締め切りはレポート締め切りの一週間前なのも注意
- 毎回の取り組みでは、「どういう意図で何をしたか」を忘れないように(レポートを書く際に重要)





北海道大学

付録 機械学習・教師あり学習

講義「人工知能」より

学習とは

知識獲得入門(知識獲得と学習シリーズ1) [1987]

- システムが前と同じタスクまたは同じ個体群から引き出されたタスクを二度目にはもっと効率よく, 効果的に行えるようにする.

岩波情報科学辞典 [1990]

- 経験により動作を改善すること.
- ある程度の長期にわたる行動の, ある目的に向かう不可逆的な変化をいう


エージェントアプローチ 人工知能 [1997, 原著1995]

- 自身の経験についての深い考察を通してその行動を改善することができる.
- 知覚が現在の行為のためだけに使われるのではなく, 未来におけるエージェントの行為能力を改善するためにも使われるべきである.



機械学習の分類

機械の持つパラメータと呼ばれる数値をより良い推定が行えるように決定・更新すること



教師あり学習

– データのラベルに基づく学習

- 画像データに「猫」「犬」など事前に意味付けを行うことをラベリングという
- データが入力されたとき対応するラベルを正しく推定できるようにする

教師なし学習

– データの特徴を表す数値(特徴量)に基づく学習

- 特徴を表す数値をもとに各データの近さを推定できるようにする
- 例) 猫の画像の特徴
 - 色、目の間の距離、耳の長さなど




入力データ(入力)を元に対応する出力を推定

– 主に分類と回帰の2つ

推定した出力の誤差が小さくなるように学習


– 分類

- 上手く○と×を分ける
線(式)を見つける



– 回帰

- 全ての点に最も近い線
(式)を見つける



例：手書き数字の画像を入力として書かれている数字が何か分類

- 手書き文字画像

画像												...	
教師ラベル	1	2	9	1	4	0	5	3	4	7	6	...	5

分類器の出力



入力



手書き
数字
分類器

(機械学習モデル)

出力



5